

Humain dans la boucle : conformité et confiance

 12 août 2026

 8 h 30 – 11 h 30

 Sherbrooke

 **STUDIO**

 En classe : **INDIVIDUEL** · Remise : **INDIVIDUEL**

 **Temps estimé** : 150 min (~2.5 h)

OBJECTIF DE LA SÉANCE

Comprendre les systèmes HITL en comparant Goldman Sachs (humain décide, IA recommande), Pfizer Charlie (revue humaine obligatoire) et Brex (IA semi-autonome). Identifier le risque d'automation bias. Produire un design d'interface HITL.

Prof. Carlos Denner dos Santos, Ph.D.

Département des systèmes d'information et méthodes quantitatives de gestion (SIMQG) - École de gestion

Université de Sherbrooke

Objectifs d'apprentissage

À LA FIN DE CETTE SÉANCE, VOUS SEREZ CAPABLE DE...

1. Classer Goldman Sachs (HITL), Brex (HOTL) et un véhicule autonome NVIDIA (HOOTL) selon les trois architectures de supervision.
2. Identifier le risque d'automation bias en contexte réel (ex. : que se passe-t-il si les analystes de Goldman cessent de vérifier les recommandations IA ?).
3. Concevoir une interface HITL qui force la vérification humaine réelle, inspirée de la gouvernance de Pfizer Charlie.
4. Produire un design d'interface HITL avec mécanismes anti-automation-bias.

POINTS CLÉS

- 💡 Goldman = HITL strict. Brex = HOTL. Pfizer = HITL maximaliste (même pour faible risque).
- 💡 L'automation bias est le danger #1 des systèmes HITL : l'humain cesse de vérifier après exposition prolongée.
- 💡 Pfizer sacrifie de l'efficacité pour de la sécurité — choix de gouvernance, pas d'UX.
- 💡 Le design de l'interface détermine si le HITL est réel ou cosmétique.
- 💡 Un HITL mal designé peut être plus dangereux qu'un HOTL bien designé (fausse impression de contrôle).
- 💡 L'audit du superviseur humain (taux d'approbation, temps de revue) est un mécanisme anti-bias essentiel.

IDÉES REÇUES À ÉVITER

⚠️ HITL = humain valide tout, donc c'est sûr

- ✓ Un HITL mal conçu est une illusion de sécurité. Si l'interface ne force pas la vérification réelle (juste un bouton 'approuver'), les humains tombent rapidement dans l'automation bias. Un HITL réel inclut : information contextuelle, mécanismes anti-bias, audit du superviseur, rotation. Sans ces composants, le HITL est cosmétique.

⚠️ L'automation bias est le problème des utilisateurs, pas du système

- ✓ L'automation bias est prévisible et systémique. Tous les humains y sont sujets après exposition prolongée. C'est une responsabilité de design, pas d'utilisateur. Les bons systèmes intègrent des mécanismes pour le contrer : tests injectés, métriques de vigilance, rotation des reviewers.

⚠️ Plus l'humain a de pouvoir d'intervention, mieux c'est

- ✓ Trop d'options paralysent. Un HOTL où l'humain peut intervenir 'à tout moment sur n'importe quelle décision' est ingérable. Le bon design définit clairement QUAND l'intervention humaine est attendue, et automatise tout le reste. Le pouvoir d'intervention sans déclencheurs clairs = pas d'intervention.

PRIORITÉS DU SOIR

CORE

hitl hotl hootl revue appliquee

automation bias mecanismes de protection

audit du superviseur humain

design force la verification reelle

STRETCH

lecons aviation transposees

calibration seuils intervention

PREVIEW

feuille route session 14

examen final session 15

Déroulement de la séance

RYTHME DE LA SOIRÉE

STRUCTURE DE LA SÉANCE

Partie	Titre	Durée	Contenu
1	Trois architectures, trois réalités	50 MIN	Rappel explicite de S08 (5 min) : 'En S08, vous avez conçu des pipelines HITL/HOTL/HOOTL — entrées, seuils, escalade, feedback. Aujourd'hui on revient sur le même cadre pour répondre à une question différente : pourquoi ces pipelines s'effondrent-ils humainement avec le temps ?' Le concept d'automation bias : le risque invisible qui fait dégrader le HITL après des semaines d'usage. Goldman (HITL), Brex (HOTL), véhicule autonome NVIDIA (HOOTL). Quand chaque architecture est requise ou recommandée. Pourquoi un HITL mal designé peut être pire qu'un HOTL bien designé — la fausse impression de contrôle.
2	Concevoir un HITL qui fonctionne	50 MIN	Cas Pfizer : forcer la revue réelle. Mécanismes anti-automation-bias : tests injectés, rotation des reviewers, métriques de vigilance, ralentissement intentionnel sur cas critiques, justification écrite obligatoire. Audit du superviseur humain (taux d'approbation, temps moyen de revue). Le contre-paradoxe : parfois ralentir l'humain améliore la sécurité globale.
3	Pause	10 MIN	Pause. Distribuer le canevas wireframe HITL.
4	Exercice : votre design HITL	40 MIN	Individuel : dessiner le wireframe annoté pour Goldman, Pfizer, Brex ou un agent du milestone M7-M10. Partage en paires (5 min chacun) avec critique sur : le mécanisme anti-bias est-il robuste ? Que se passe-t-il après 6 mois d'usage ? 2-3 partages au groupe.

INTERACTIONS WOOC LAP

POLL

Vous êtes analyste, et l'agent vous propose 50 recommandations à valider par jour. Après 3 mois, vous :

WORD_CLOUD

Quel mécanisme rendrait votre vérification humaine vraiment effective ?

OBJECTIF

Concevoir une interface HITL réelle (pas cosmétique) qui résiste à l'automation bias et inclut audit du superviseur humain. Démontrer la compréhension des trade-offs sécurité/efficacité.

LIVRABLE ATTENDU

Wireframe annoté (1 page)

ARTÉFACTS DU REPO

- ☐ portfolio/M11_design_hitl.pdf
- ☐ ai-usage.md

CHECKLIST DE REMISE

- ☐ Interface dessinée (wireframe ou schéma lisible)
- ☐ Mécanisme anti-automation-bias explicite (pas juste un bouton 'approuver')
- ☐ Critères d'escalade automatique chiffrés
- ☐ Boucle de feedback identifiée
- ☐ Mécanismes d'audit du superviseur humain
- ☐ Justification annotée de chaque choix
- ☐ Divulgence IA si applicable

Remise & évaluation

ARTÉFACTS REQUIS

- ☐ portfolio/M11_design_hitl.pdf
- ☐ ai-usage.md

RÈGLE DE REMISE

 Avant la séance 14 (19 août 2026)

CRITÈRES D'ÉVALUATION

%	Dimension	Accent de la séance
15%	Lisibilité wireframe	Wireframe lisible avec zones agent/humain claires.
30%	Mécanisme anti automation bias	Mécanisme structurel (pas juste 'demander à l'humain de vérifier').
15%	Critères escalade	Critères d'escalade chiffrés et justifiés.
15%	Boucle feedback	Boucle de feedback opérationnelle (humain corrige, agent réapprend).
15%	Audit superviseur	Mécanismes d'audit du superviseur humain présents.
5%	Justification annotée	Choix annotés avec justification.
5%	Ai disclosure	ai-usage.md présent.

EXIT TICKET

 En une phrase : pour votre futur métier, identifiez UN mécanisme anti-automation-bias que vous mettriez en place pour vous-même quand vous travaillez avec un agent IA.

DIVULGATION IA — AI-USAGE.MD

1

Outil utilisé
Nom, version, date d'accès

2

Ce qu'il m'a aidé à faire
Tâche précise — pas « écrire le travail »

3

Sources et chiffres vérifiés
Chaque affirmation → source primaire consultée

4

Ce que j'ai modifié ou rejeté
Corrections, reformulations, refus — et pourquoi

5

Déclaration de responsabilité
Je suis responsable de l'exactitude et du jugement — outil IA utilisé ou non.

Présent même si aucun outil IA utilisé · gabarit : [content/templates/ai-usage.md](#)

Outils & règles IA

POLITIQUE IA

IA PERMISE

Les outils IA sont permis lorsqu'explicitement indiqué. Toute utilisation doit être divulguée dans ai-usage.md. L'étudiant demeure responsable de l'exactitude, du jugement et de la vérification.

OUTILS PAR DÉFAUT

chatgpt or copilot

google docs

slides

canva

POLITIQUE CLOUD

AUCUNE CARTE REQUISE

Voie par défaut: analytics

Lectures recommandées



Parasuraman & Manzey — Complacency and Bias in Human Use of Automation (2010)

La référence académique sur l'automation bias.

<https://journals.sagepub.com/doi/10.1177/0018720810376055>



Goldman Sachs Engineering Blog (HITL practices)

Insights publics sur les architectures HITL chez Goldman.

<https://developer.gs.com/>



Pfizer Digital Engineering — Charlie governance

Insights sur la revue humaine universelle chez Pfizer.

<https://www.pfizer.com/news>



FAA — Automation in Cockpits (lessons for HITL design)

Leçons aviation transposables au HITL en entreprise.

<https://www.faa.gov/>